


Prédiction du Trafic Urbain à partir de la Structure Cartographique




Caramella Enzo
Albaladejo Guilhem
Falcão Barreto Felipe Mateus

1. Contexte et Problématique



- Prédire le trafic urbain
- Sans données collectées en temps réel
- Pouvoir généraliser à toute agglomération

2. Données de la ville de New York



Nodes: 95 581 intersections (nœuds du graphe)

Links: 260 855 segments routiers (arêtes du graphe)

Travel_times: 103M observations de temps de parcours (variable cible)

=> Traitement des données nécessaire (5Gb)

3. Traitement des données



3. Traitement des données

3.1 Nettoyage des données




Suppression:

- Champs redondants
- Champs Non-exploités
- Données invalides
- Données incomplètes

3. Traitement des données

3.2 Enrichissement via l'API OSM



Centroide calculé avec nos données.



3. Traitement des données


3.3 Post-traitement et extraction des features

$$Z = \frac{x - \mu}{\sigma}$$

Score (pointing to x), Mean (pointing to μ), SD (pointing to σ)

Objectifs:

- Données indépendantes de leur contexte
- Séparation features / labels
- Exploitable directement par Random Forest



4. Description des Features

13 features organisées en 3 catégories

Caractéristiques route	road_type, max_speed, lanes, angle
Contexte spatial	landuse, landuse_way_dest, place, place_way_dest, centrality, num_begin_links, num_out_links
Contexte temporel	hour, is_weekend

4. Choix des features

road_type + max_speed : Contraintes de la voie (résidentielle, voie rapide)

landuse / place : Type de zone (commercial, résidentiel...)

centrality: Distance normalisée au centre-ville

num_links : Complexité des intersections


angle: Virages serrés ralentissent le trafic

hour + is_weekend: Heures de pointe, week-end

Variable cible : $\text{speed (km/h)} = (\text{street_length} / \text{travel_time}) \times 3.6$

5. Modélisation

Régression par Random Forest



Hyperparamètres:

- n_estimators=200
- min_samples_leaf=5
- max_features=0.5
- max_depth=30,
- bootstrap=False

(Trouvés par random search)

Random Forest > GNN □
optimisation du temps et du projet

6. Résultats et Analyse

Train / test split: 80%, 20%

Métriques du modèle:

- Mean average error: 7.611
- Root mean squared error: 12.74
- Coefficient de détermination R2: 0.472

Vitesses prédites:

- Moyenne: 32.82 km/h
- Medianne: 30.95 km/h
- Min: 4.99 km/h
- Max: 104.7 km/h


7. Organisation et gestion de projet

- ✓ Contraintes et objectifs
- ✓ Répartition des tâches par membre et par semaine
- ✓ Communication et mise en commun régulière
- ✗ Perte de temps avec l'approche GNN
- ✗ Complexité de l'approche GNN
- ✗ Retour en arriere, approche RandomForest


7 Diagramme de Gantt

Tâche	Responsable	Semaine 1(01-07)	Semaine 2(08-14)	Semaine 3(15-21)	Semaine 4(22-29)
Analyse exploratoire des données	TOUS				
Nettoyage links & nodes	Enzo				
Nettoyage travel_times	Guillhem				
Enrichissement	Guillhem/Enzo				
Post traitement et choix des features	Felipe				
Création table d'entraînement	Guillhem/ENZO				
Tentative GNN / Traitement variables catégorielles	TOUS				
Implémentation RF	TOUS				
Boucle d'Entraînement & Debug	TOUS				
Évaluation modèle (MAE/RMSE/R ²)	Guillhem				
Hyperparamètres	Enzo/Guillhem				
Test généralisation Marseille	Felipe				
Visualisation carte Marseille	Felipe				
Rédaction Rapport & Slides	TOUS				

8. Prediction du trafic a Marseille



9. Visualisation Interactive du trafic



- ✓ télécharger et convertir en GeoDataFrame le graphe de Marseille
- ✓ lecture du CSV avec les vitesses prévues
- ✓ création de la légende des couleurs
- ✓ création de la carte avec les rues colorées selon la vitesse avec folium

exemple avec les
valeurs suivantes:
hour = 12
is_weekday = 0

10. Conclusion

Résultats

- $R^2 = 0.472 \rightarrow 47\%$ de la variance expliquée
- $MAE = 7.61$ km/h

Validation de l'hypothèse

- La structure urbaine prédit une part significative du comportement du trafic

Limites

- 53% de variance non expliquée (météo, incidents, événements)
- Entraîné uniquement sur New York 2013

Perspectives

- Features supplémentaires
- Test sur d'autres villes (Marseille)
- Modèles alternatifs (NN, GNN)

Apport personnel

- Application concrète ML et Data Mining
- Gestion de données volumineuses (~5 Go, 103M lignes)